Livrable 1 — Spécifications techniques

SmartTicket — Gestionnaire de tickets avec assistant IA (RAG)

> **Note méthodologique** : ce document décrit l'implémentation **réelle** telle qu'elle existe dans le code source au 2026-05-08. Toutes les informations sont tirées de l'exploration directe du dépôt, pas d'un document de conception théorique.

1.1 Architecture applicative effective

Style architectural constaté

L'architecture est un **backend-for-frontend (BFF) à deux niveaux** :

- Un **backend monolithe modulaire** (FastAPI) exposant une API REST, organisé en 7 routers thématiques.
- Un **frontend Next.js** jouant à la fois le rôle d'interface utilisateur et de proxy BFF (les routes `/api/*` de Next redirigent vers le backend via des `rewrites` et un handler SSR pour le streaming).

> **Écart vs architecture initiale** : le cahier d'architecture initial décrivait potentiellement une architecture microservices multi-services. L'implémentation effective est un monolithe modulaire à 2 services déployés + 1 base de données managée. Ce choix est cohérent avec les contraintes de coût (plan gratuit Render.com).

Services effectivement présents

Service 1 — Backend API (`backend/`)

Attribut	Valeur
Rôle	API REST, pipeline RAG, gestion des sessions/messages/utilisateurs, analytics
Framework	FastAPI (Python 3.11)
Port	8000
Localisation	`backend/`

Routers et endpoints exposés (tous préfixés `/v1`) :

Router	Fichier	Endpoints
Authentification	`routers/auth.py`	POST /register, POST /login, POST /logout, GET /me, PUT /me, PUT /me/password
Sessions	`routers/sessions.py`	POST /sessions, GET /sessions, DELETE /sessions/{id}, POST /sessions/{id}/close, POST /sessions/{id}/transfer, POST /sessions/{id}/resolve, GET /sessions/transferred

Router	Fichier	Endpoints
Messages	`routers/messages.py`	GET /messages, POST /messages, PATCH /messages/{id}/feedback
IA/RAG	`routers/ai.py`	POST /ask/stream
Base de connaissances	`routers/knowledge.py`	POST /knowledge-base/ingest-url, GET /knowledge-base/ingest-status, GET /knowledge-base/robots-check, GET /knowledge-base/sources, DELETE /knowledge-base/sources, POST /knowledge-base/ingest-file
Utilisateurs	`routers/users.py`	GET /users, PUT /users/{id}/role, PUT /users/{id}, DELETE /users/{id}
Analytics	`routers/analytics.py`	GET /analytics/stats

Dépendances externes : Mistral AI API (`https://api.mistral.ai/v1`)

Service 2 — Frontend (`frontend/`)

Attribut	Valeur
Rôle	Interface utilisateur, proxy BFF pour le streaming SSE
Framework	Next.js 16.1.6 (App Router)
Port	3005
Localisation	`frontend/`

Routes applicatives :

Route	Rôle
`/`	Dashboard (liste des sessions de chat)
`/ai-assistant/[id]`	Interface de chat avec l'assistant IA
`/analytics`	Dashboard analytique (admin/SAV uniquement)
`/knowledge-base`	Gestion de la base de connaissances
`/settings`	Paramètres de profil utilisateur
`/login`, `/sign-up`, `/forgot-password`	Authentification

Proxy API : `next.config.ts` redirige `/api/*` → `backend:8000/v1/*` via `rewrites()`. Le handler `app/api/ask/route.ts` proxifie spécifiquement le streaming de l'endpoint `/v1/ask/stream`.

Service 3 — PostgreSQL + pgvector

Attribut	Valeur
Image	`pgvector/pgvector:pg16` (local) / PostgreSQL managé Render (pré-prod)
Port	5432
Base	`ticketdb`
Extensions	`vector` (pgvector), `pgcrypto`
Index	HNSW sur `knowledge_base.embedding` (cosine_ops)

Service 4 — Redis (local uniquement)

Attribut	Valeur
Image	`redis:7-alpine`
Port	6379
Usage en prod	Non déployé — prévu pour la mise en cache, non connecté dans le code backend actuel

---

Diagramme C4 — Niveau Container (basé sur le code réel)

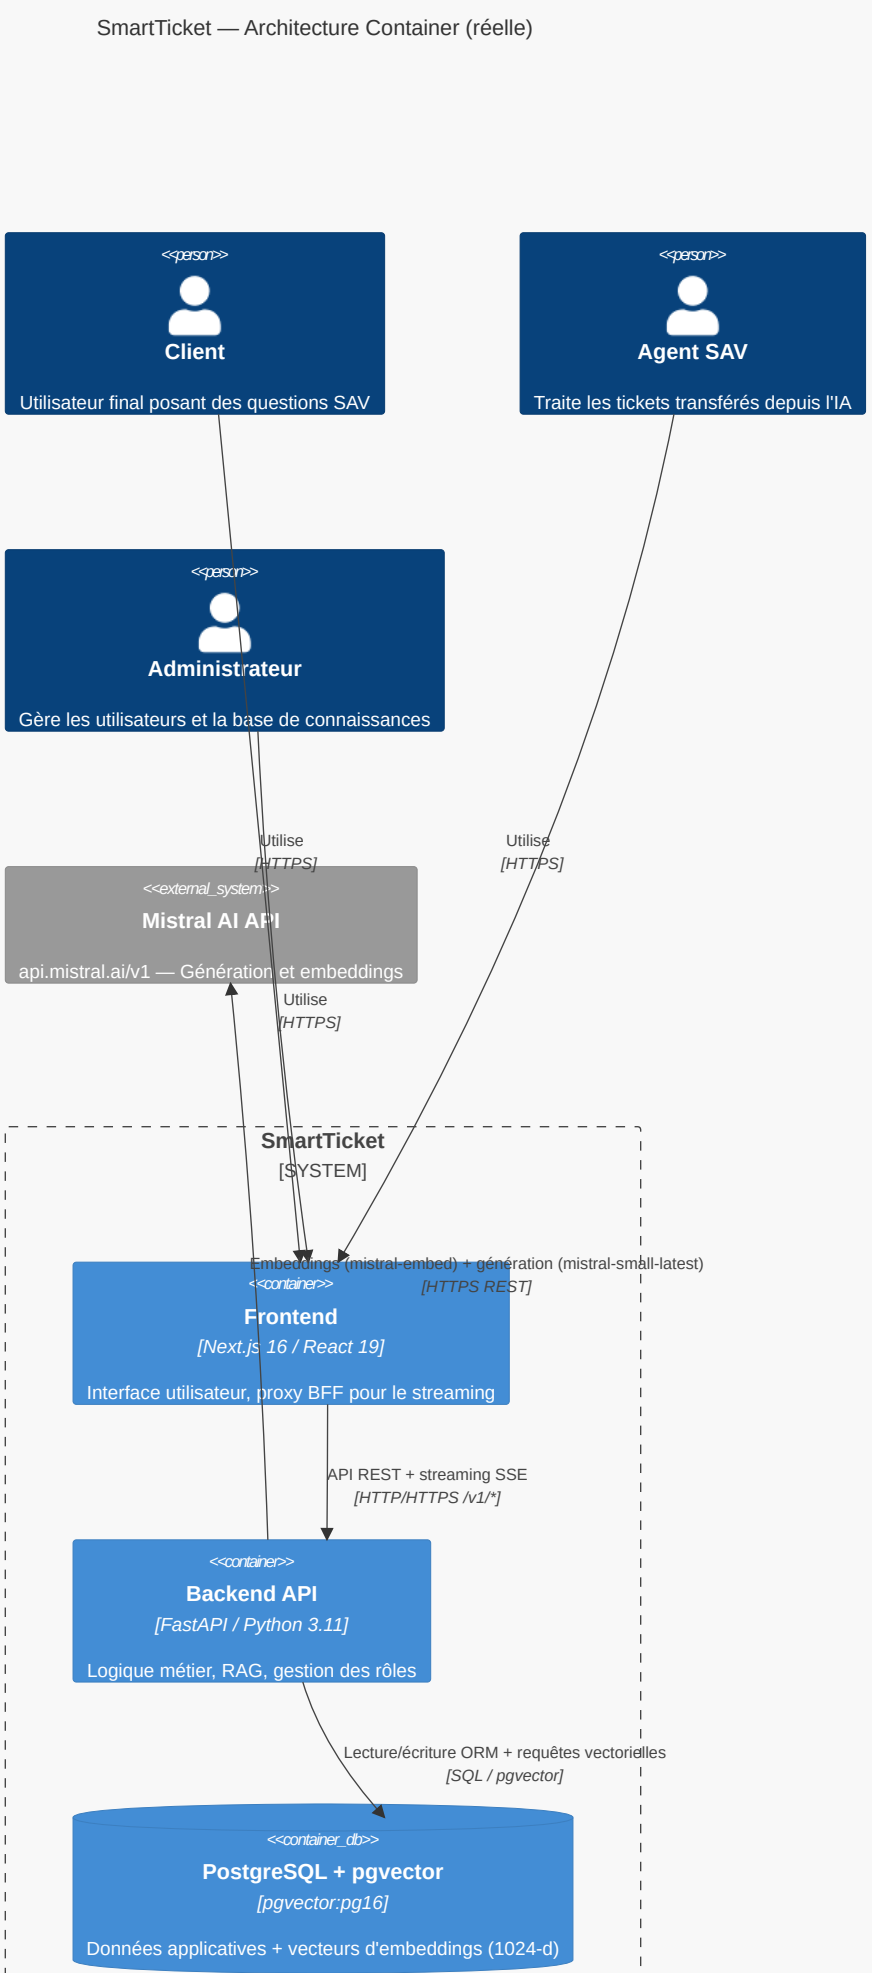
SmartTicket — Architecture Container (réelle)
<<person>>
Client
Utilisateur final posant des questions SAV
<<person>>
Agent SAV
Traite les tickets transférés depuis l'IA
<<person>>
Administrateur
Gère les utilisateurs et la base de connaissances
Utilise
[HTTPS]
Utilise
[HTTPS]
<<external_system>>
Mistral AI API
api.mistral.ai/v1 — Génération et embeddings
Utilise
[HTTPS]
SmartTicket
[SYSTEM]
Embeddings (mistral-embed) + génération (mistral-small-latest)
[HTTPS REST]
<<container>>
Frontend
[Next.js 16 / React 19]
Interface utilisateur, proxy BFF pour le streaming
API REST + streaming SSE
[HTTP/HTTPS /v1/*]
<<container>>
Backend API
[FastAPI / Python 3.11]
Logique métier, RAG, gestion des rôles
Lecture/écriture ORM + requêtes vectorielles
[SQL / pgvector]
<<container_db>>
PostgreSQL + pgvector
[pgvector:pg16]
Données applicatives + vecteurs d'embeddings (1024-d)

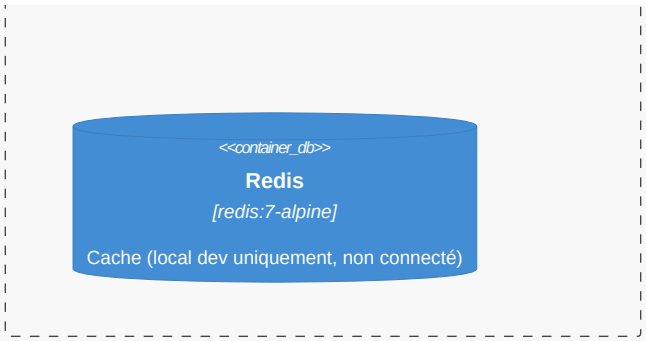

1.2 Stack technique effective

Frontend (`frontend/package.json`)

Lib	Version	Rôle
next	^16.1.6	Framework React (App Router, SSR, API routes)
react	19.2.3	Moteur UI
react-dom	19.2.3	Rendu DOM
typescript	^5	Typage statique
tailwindcss	^4	CSS utilitaire
@radix-ui/react-dialog	^1.1.15	Modaux accessibles (WCAG 2.1)
@base-ui/react	^1.0.0	Composants UI accessibles
radix-ui	^1.4.3	Suite de primitives UI
lucide-react	^0.562.0	Icônes SVG
recharts	^3.6.0	Graphiques SVG (dashboard analytics)
shadcn	^3.6.3	Générateur de composants basé Radix
streamdown	^2.4.0	Rendu Markdown pour réponses streamées
clsx + tailwind-merge	^2.1.1 / ^3.4.0	Gestion conditionnelle des classes CSS
tw-animate-css	^1.4.0	Animations CSS déclaratives

Outils de test frontend : jest ^29, @testing-library/react ^16, ts-jest ^29

Backend (`backend/requirements.txt`)

Lib	Version	Rôle
fastapi	latest	Framework API REST async

Lib	Version	Rôle
uvicorn	latest	Serveur ASGI
sqlalchemy	latest	ORM Python
psycopg2-binary	latest	Driver PostgreSQL
pgvector	latest	Extension pgvector pour SQLAlchemy
passlib[bcrypt]	latest	Hachage de mots de passe
bcrypt	4.0.1	Algorithme bcrypt (épinglé pour compatibilité)
python-jose[cryptography]	latest	Génération/validation JWT HS256
email-validator	>=2.0.0	Validation format email (Pydantic)
python-dotenv	latest	Chargement des variables d'environnement
requests	latest	Client HTTP synchrone (appels Mistral API)
langchain-community	latest	Scraping web + intégrations LangChain
langchain-text-splitters	latest	Découpage de texte en chunks pour le RAG
beautifulsoup4	latest	Parsing HTML (ingestion de pages web)
lxml	6.0.2	Parser XML/HTML performant
pypdf	6.9.2	Lecture et extraction de texte PDF
python-docx	1.2.0	Lecture de fichiers DOCX
typing-extensions	4.15.0	Compatibilité types Python

Outils de test backend : pytest, pytest-cov, httpx

Bases de données et services

Service	Image Docker	Version	Usage
PostgreSQL	`pgvector/pgvector:pg16`	PostgreSQL 16 + pgvector	Données applicatives et vectorielles
PostgreSQL (CI)	`pgvector/pgvector:pg15`	PostgreSQL 15 + pgvector	Tests d'intégration CI uniquement
Redis	`redis:7-alpine`	Redis 7	Prévu pour cache (non connecté en prod)
pgAdmin	`dpage/pgadmin4`	latest	Administration DB (dev uniquement)
Ollama	`ollama/ollama:latest`	latest	LLM local (dev uniquement, non utilisé en prod)

Service	Image Docker	Version	Usage
Open WebUI	`ghcr.io/open-webui/open-webui:main`	latest	Interface Ollama (dev uniquement)

Services IA

Modèle	Fournisseur	Usage	Variable d'env
`mistral-small-latest`	Mistral AI	Génération de réponses (streaming SSE) + résumés de sessions à la clôture	`MISTRAL_MODEL`
`mistral-embed`	Mistral AI	Vectorisation des questions et des documents (1024 dimensions)	`EMBED_MODEL`

Code source : `backend/mistral_client.py` (fonctions `stream_text`, `generate_text`, `embed_text`)

1.3 Dépendances et environnement d'exécution

Backend (`backend/Dockerfile`)

Paramètre	Valeur
Image de base	`python:3.11-slim`
Dépendances système	`libpq-dev`, `gcc` (pour psycopg2-binary)
Port exposé	8000
Commande de démarrage	`uvicorn main:app --host 0.0.0.0 --port ${PORT:-8000}`
Variables d'env requises	`SECRET_KEY`, `DATABASE_URL`, `MISTRAL_API_KEY`, `CORS_ORIGINS`
Variables d'env optionnelles	`ALGORITHM`, `ACCESS_TOKEN_EXPIRE_MINUTES`, `MISTRAL_MODEL`, `EMBED_MODEL`, `KB_TOP_K`, `KB_MAX_CONTEXT_CHARS`, `SUMMARY_MAX_CHARS`
Volumes	`./backend:/app` (dev)

Frontend (`frontend/Dockerfile`)

Paramètre	Valeur
Image de base	`node:20-slim`
Build arg	`NEXT_PUBLIC_API_URL` (injecté au moment du build)
Port exposé	3005
Commande de démarrage	`npm run start -- -p ${PORT:-3005}`

Paramètre	Valeur
Variables d'env requises	`NEXT_PUBLIC_API_URL`
Mode	`NODE_ENV=production`

PostgreSQL (`docker-compose.yml`)

Paramètre	Valeur
Image	`pgvector/pgvector:pg16`
Port	5432
Volumes	`./data/postgres:/var/lib/postgresql/data`
Init SQL	`./backend/db/init-db.sql` (extensions, tables, index HNSW, compte admin par défaut)
Variables d'env	`POSTGRES_DB=ticketdb`, `POSTGRES_USER=admin`, `POSTGRES_PASSWORD=Password1234`

1.4 Sécurité implémentée

Authentification

JWT (HS256) + Cookie httpOnly — `backend/dependencies.py:38-59` + `backend/routers/auth.py:37-48`

```
dependencies.py:38   SECRET_KEY = os.getenv("SECRET_KEY")
dependencies.py:39   ALGORITHM = os.getenv("ALGORITHM", "HS256")
dependencies.py:40   ACCESS_TOKEN_EXPIRE_MINUTES =
int(os.getenv("ACCESS_TOKEN_EXPIRE_MINUTES", 60))
auth.py:41           response.set_cookie(key="auth_token",
value=access_token, httponly=True,
auth.py:42               samesite="strict", secure=cookie_secure,
max_age=ACCESS_TOKEN_EXPIRE_MINUTES * 60)
```

Le token est émis dans un cookie `httpOnly` + `SameSite=strict` (protection CSRF et XSS). Il peut aussi être transmis via header `Authorization: Bearer` (dual mode).

Validation du token — `backend/dependencies.py:62-75`

```
dependencies.py:62   def get_current_user(request: Request, token: str |
None = Depends(oauth2_scheme)) -> str:
dependencies.py:63       if not token:
dependencies.py:64           token = request.cookies.get("auth_token")
dependencies.py:67       payload = jwt.decode(token, SECRET_KEY,
algorithms=[ALGORITHM])
```

Hachage des mots de passe — `backend/dependencies.py:30` + `backend/db/init-db.sql`

```
dependencies.py:30   pwd_context = CryptContext(schemes=["bcrypt"],
deprecated="auto")
init-db.sql:         crypt('admin', gen_salt('bf'))   -- bcrypt via
pgcrypto
```

RBAC (Contrôle d'accès basé sur les rôles)

4 rôles : `user`, `ai`, `sav`, `admin`

Vérification des rôles — `backend/dependencies.py:78-82`

```
dependencies.py:78   def is_admin_or_sav(user: models.Utilisateur | None) -
> bool:
dependencies.py:79       if not user or not user.role:
dependencies.py:80           return False
dependencies.py:81       return user.role.nom_role in ["admin", "sav"]
```

Utilisé sur : `GET /analytics/stats`, `GET /sessions/transferred`, `POST /knowledge-base/ingest-url`, `POST /knowledge-base/ingest-file`, `DELETE /knowledge-base/sources`, `GET /users`, `PUT /users/{id}/role`, `PUT /users/{id}`, `DELETE /users/{id}`

Vérification admin stricte sur les routes d'administration (`users.py` vérifie `nom_role == "admin"` directement).

CORS

Middleware CORS — `backend/main.py:28-38`

```
main.py:28   cors_origins = [origin.strip() for origin in
os.getenv("CORS_ORIGINS", "...").split(",")]
main.py:36   app.add_middleware(CORSMiddleware,
main.py:37       allow_origins=cors_origins, allow_credentials=True,
main.py:38       allow_methods=["*"], allow_headers=["*"])
```

Les origines autorisées sont configurées via la variable `CORS_ORIGINS`. En pré-production, Render injecte automatiquement l'URL du frontend.

Validation des entrées

Pydantic v2 — `backend/schemas.py` : tous les payloads entrants sont validés par des modèles Pydantic avec `EmailStr`, `HttpUrl`, contraintes de longueur. Exemple : `AskRequest`, `UserCreate`, `TransferRequest`.

Sanitisation des textes — `backend/dependencies.py:25`

```
dependencies.py:25   def sanitize_text(value: str) -> str:
dependencies.py:26       return value.replace("\x00", "").strip()
```

Suppression des caractères nuls avant stockage (protection contre l'injection PostgreSQL via NULL bytes).

Gestion des secrets

Les secrets sont externalisés via variables d'environnement (`.env` non commité). En pré-prod Render, `SECRET_KEY` est généré automatiquement (`generateValue: true` dans `render.yaml`). `MISTRAL_API_KEY` est injecté manuellement dans les variables d'environnement Render.

Vérification au démarrage — `backend/main.py:19`

```
main.py:19   if not os.getenv("SECRET_KEY"):
main.py:20       raise RuntimeError("SECRET_KEY manquante.")
```

Mesures OWASP non implémentées (lacunes honnêtes)

Vulnérabilité OWASP API	Statut	Recommandation
Rate limiting (API2:2023)	✗ Absent	Ajouter `slowapi` (limiter sur `/v1/login`, `/v1/ask/stream`)
Security headers (Helmet)	✗ Absent	Ajouter `secure-headers` middleware ou configurer Nginx/Caddy en reverse proxy
Refresh tokens	✗ Absent	Token JWT fixe 60 min. Implémenter rotation via Redis
Audit log	✗ Absent	Les suppressions et changements de rôle ne sont pas journalisés (sauf `DELETE /knowledge-base/sources` — `logger.info` présent dans `knowledge.py:37`)
Validation de la taille des uploads	⚠️ Partiel	`ingest-file` vérifie l'extension mais pas la taille du fichier en bytes

---

1.5 Méthodologie de développement constatée

Workflow Git

Branche principale : `master`. Développement direct sur master (commits récents : `ajout de la fonction c14`, `validation c10`, `correction pour CI`, `amélioration de la structure du main`).

Convention de commits : messages en français, style descriptif court (ex : `ajout d'analyse des analytics des réponses de l'ia`, `correction pour CI`).

Pipeline CI/CD

Déclenché sur push et pull request vers `master`. Deux jobs :

```
Job 1 — backend-tests :
  Python 3.11 → pip install → pytest tests/ -v --tb=short
  (service postgres pgvector:pg15 en sidecar)

Job 2 — frontend-tests :
  Node 20 → npm ci → tsc --noEmit → eslint → jest → npm run build
```

Tests

Backend (`backend/tests/`) :

- `test_api.py` : tests d'intégration couvrant auth (register, login, logout, profil), sessions (create, list, accès inter-utilisateurs), messages
- `test_utils.py` : tests unitaires utilitaires
- `conftest.py` : fixtures (client HTTP, utilisateur inscrit, client authentifié)
- Framework : pytest + httpx (`TestClient` FastAPI)

Frontend (`frontend/__tests__/`) :

- `api.test.ts` : tests de l'API proxy
- `utils.test.ts` : tests utilitaires
- Framework : jest + @testing-library/react

Couverture : configurée via `pytest-cov` (rapport non quantifié dans le repo).

1.6 Environnements

Environnement de développement local

Tous les services orchestrés par `docker-compose.yml` :

Service	URL locale
Frontend	http://localhost:3005
Backend API	http://localhost:8000
Swagger UI	http://localhost:8000/docs
pgAdmin	http://localhost:5050
Ollama	http://localhost:11434
Open WebUI	http://localhost:3002

Commande : `docker compose up -d --build`

Environnement de pré-production (Render.com)

Service	Hébergeur	URL
Backend	Render.com (Free)	`https://pfe-ece-backend.onrender.com` *(à confirmer)*
Frontend	Render.com (Free)	`https://pfe-ece-frontend.onrender.com` *(à confirmer)*
PostgreSQL	Render.com Managed DB (Free)	Interne au réseau Render

> **Action requise** : confirmer les URLs réelles de pré-production avant livraison finale du livrable 4.

Déploiement déclenché manuellement via `render.yaml` (ou push Git si Render est connecté au dépôt GitHub).

Environnement de production

Pas d'environnement de production distinct de la pré-production à ce stade du projet.